Clasificación del uso de mascarilla en rostros mediante redes neuronales convolucionales

Jose Eduardo Perez Abundiz · A01666860

Instituto Tecnológico y de Estudios Superiores de Monterrey, Campus Querétaro

Inteligencia artificial avanzada para la ciencia de datos (Gpo 601)

Profesor: Dr. Benjamín Valdés

Resumen

Este trabajo estudia la clasificación del uso de mascarillas en rostros mediante redes neuronales convolucionales. A partir de 853 imágenes con anotaciones, se realizó una revisión de calidad y se prepararon 3,603 recortes de rostros para distinguir tres clases: mascarilla bien puesta, ausencia de mascarilla y mascarilla mal puesta. Las imágenes originales se separaron en conjuntos de entrenamiento, validación y prueba antes de asignar sus recortes, evitando compartir rostros de una misma fotografía entre conjuntos. En este estudio se entrenaron y compararon dos CNN: una básica y otra con un bloque convolucional adicional. La CNN profunda alcanzó una accuracy de validación de 95.41%, mientras que la básica obtuvo un F1 macro mayor (0.7725) y reconoció más casos de mascarilla mal puesta. Por este motivo, la CNN básica se integró provisionalmente en una interfaz local que permite clasificar un rostro recortado. Los resultados muestran el funcionamiento del prototipo y señalan que la clase de uso incorrecto, poco representada en el conjunto de datos, sigue siendo el principal reto.

Palabras clave: redes neuronales convolucionales; clasificación de imágenes; uso de mascarillas; deep learning; matriz de confusión.

1. Introducción

Reconocer si una persona lleva mascarilla requiere distinguir más que su presencia o ausencia: también puede estar colocada de forma incorrecta. La clasificación de estas situaciones en imágenes permite estudiar cómo una red neuronal convolucional aprende características visuales de cada caso y explorar su utilidad como apoyo en lugares donde se requiera el uso de mascarillas.

Este proyecto utiliza el conjunto Face Mask Detection [1], cuyas anotaciones identifican rostros y los clasifican en tres categorías: mascarilla bien puesta, sin mascarilla y mascarilla mal puesta. El objetivo es preparar esos rostros, construir y comparar distintas configuraciones de CNN y analizar sus aciertos y errores para seleccionar la más adecuada entre las evaluadas.

En este trabajo se comparan dos arquitecturas y se integra la seleccionada provisionalmente en una interfaz local. El modelo clasifica un rostro previamente recortado; la localización automática de rostros en una fotografía completa no forma parte de esta implementación.

2. Datos y análisis exploratorio

El conjunto contiene 853 imágenes PNG y 853 archivos XML con cuadros delimitadores y etiquetas. Se identificaron 4,072 rostros; 524 fotografías contenían más de uno. Por ello, una imagen original puede producir varios ejemplos para la clasificación.

Clase	Rostros	%
with_mask	3,232	79.37
without_mask	717	17.61
mask_weared_incorrect	123	3.02

Tabla 1. Distribución original de las clases.

La clase de uso incorrecto tiene una representación reducida. Esta diferencia de frecuencias exige revisar los errores por clase y no interpretar la accuracy general de forma aislada.

3. Calidad de imágenes y anotaciones

Se comprobó que las 853 imágenes pueden abrirse, que cada XML tiene su imagen correspondiente y que las dimensiones declaradas coinciden con las dimensiones reales. Las imágenes tienen tamaños distintos, lo cual debe considerarse al preparar entradas uniformes para la CNN. Se encontraron 12 cuadros delimitadores cuyo límite derecho excedía en exactamente un píxel el ancho de su imagen; no se encontraron cuadros sin área ni etiquetas desconocidas.

Verificación	Resultado
Pares imagen-XML	853; ninguno faltante
Dimensiones diferentes	0
Cuadros fuera del borde	12; exceso de 1 px
Tamaño mediano rostro	22 x 24 px
Dimensión menor de 10 px	469 (11.52%)
Modos de color	831 RGBA; 22 RGB
Transparencia	638 imágenes; 6 recortes conservados

Tabla 2. Resumen de la revisión de calidad.

La inspección visual mostró que los rostros de menos de 10 píxeles en alguna dimensión carecen de detalle suficiente para distinguir la posición de la mascarilla. Un límite de 20 píxeles habría excluido 1,821 rostros (44.72%), por lo que se eligió el criterio menos restrictivo. La transparencia de los seis recortes afectados se concentró principalmente en franjas de sus bordes.

4. Preparación de los datos

Como una fotografía puede incluir varios rostros con distintas etiquetas, se tomó cada rostro delimitado como una observación. A partir de sus coordenadas en el XML se extrajo el recorte y se conservó su clase. Se excluyeron 469 anotaciones con menos de 10 píxeles en alguna dimensión y se conservaron 3,603 rostros. En los cuadros que sobrepasaban el borde derecho, la coordenada se ajustó al ancho real antes de recortar. Esta corrección afectó a ocho de los rostros conservados.

Los recortes se convirtieron a RGB. Cuando había transparencia, se colocaron sobre un fondo blanco antes de retirar el canal alfa. Después, cada rostro se redimensionó a 128 x 128 píxeles mediante interpolación bilineal. La uniformidad permite procesar imágenes por lotes, aunque el redimensionamiento puede alterar ligeramente sus proporciones. La escala de píxeles se ajusta dentro de la CNN.

Las fotografías originales se dividieron antes de asignar sus recortes: todos los rostros procedentes de una misma fotografía quedaron en un solo conjunto. Se buscó una proporción aproximada de 70% para entrenamiento, 15% para validación y 15% para prueba, considerando las clases presentes en cada fotografía.

Conjunto	Fotos	Rostros
Entrenamiento	597	2,574
Validación	128	545
Prueba	128	484

Tabla 3. División por fotografía original.

El número de rostros no sigue exactamente la proporción 70/15/15 porque cada fotografía contiene una cantidad distinta de rostros. El conjunto de entrenamiento ajusta la CNN; el de validación compara configuraciones; el de prueba permanece reservado para la evaluación final.

Clase	Ent.	Val.	Prueba
with_mask	2,035	454	388
without_mask	456	75	77
mal puesta	83	16	19

Tabla 4. Rostros conservados por clase y conjunto.

La clase con mascarilla bien puesta predomina en los tres conjuntos. En validación solo hay 16 ejemplos de mascarilla mal puesta, de modo que unos pocos aciertos o errores modifican considerablemente sus métricas.

5. Modelos convolucionales

Cada entrada es un rostro RGB de 128 x 128 píxeles y, durante el entrenamiento, su etiqueta original. La CNN aprende patrones visuales del recorte; no se programaron reglas específicas para reconocer una mascarilla. Los filtros convolucionales extraen patrones locales, las capas posteriores combinan esa información y una capa Rescaling transforma los píxeles de 0-255 a 0-1 [2]. La salida softmax produce un valor para cada una de las tres clases.

Se implementaron dos CNN. Ambas utilizan convoluciones con ReLU, agrupamiento máximo, Flatten, una capa densa de 32 neuronas y una salida de tres clases. La segunda agrega un tercer bloque convolucional.

Modelo	Bloques / filtros	Parámetros
Básica	2: 16, 32	926,819
Profunda	3: 16, 32, 64	425,123

Tabla 5. Arquitecturas evaluadas.

La CNN profunda posee menos parámetros porque el tercer agrupamiento reduce el tamaño de la entrada a la capa densa. La profundidad adicional no garantiza un mejor desempeño; se compara experimentalmente en validación.

6. Configuración del entrenamiento

Ambas CNN se entrenaron durante 10 épocas con lotes de 32 recortes. En cada lote, la red produce predicciones, calcula una pérdida y obtiene gradientes para actualizar sus parámetros. Se usó sparse categorical crossentropy porque cada rostro tiene una sola etiqueta codificada como número entero [2]. La función penaliza que el modelo asigne un valor bajo a la clase correcta.

Para actualizar los parámetros se eligió Adam. Este optimizador utiliza los gradientes y mantiene información de sus valores recientes y de su magnitud para adaptar las actualizaciones de cada parámetro [3]. Fue una elección práctica para entrenar ambas CNN con una configuración sencilla y constante. Se registraron la pérdida y la accuracy de entrenamiento y validación en cada época. Después se calcularon precisión, recall, F1 y matrices de confusión por clase [4].

7. Resultados de entrenamiento

Ambas CNN redujeron su pérdida de entrenamiento. Al finalizar la época 10, la profunda alcanzó una accuracy de validación ligeramente mayor: 95.41% frente a 94.68%.

Modelo	Acc. ent.	Acc. val.	Pérd. val.
Básica	97.01%	94.68%	0.1472
Profunda	97.44%	95.41%	0.1798

Tabla 6. Resultados al finalizar la época 10.

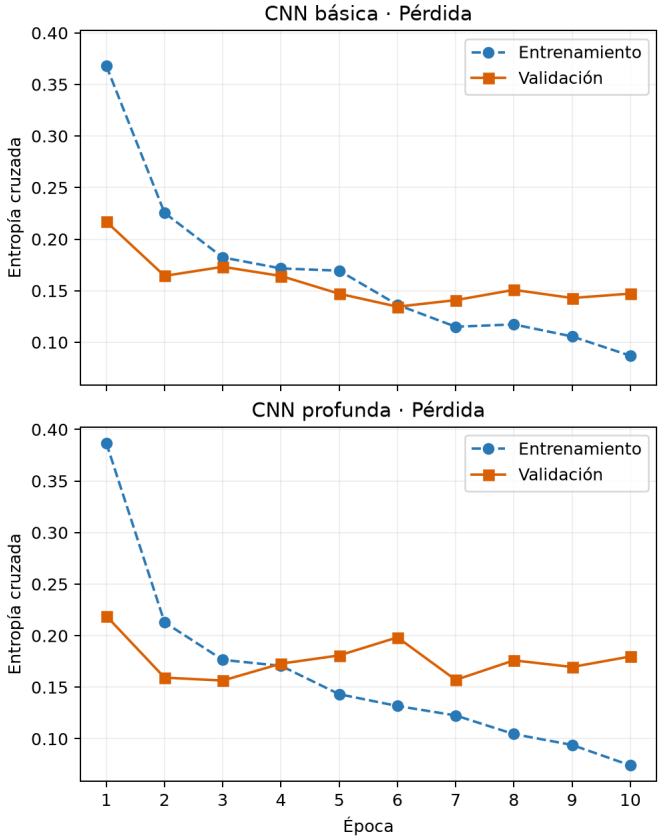


Figura 1a. Pérdida de entrenamiento y validación de ambas CNN.

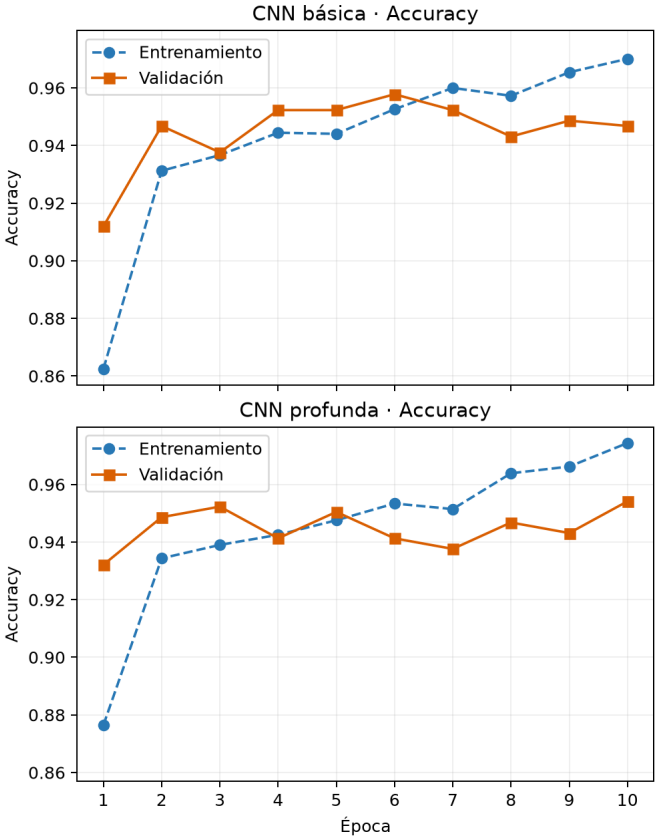


Figura 1b. Accuracy de entrenamiento y validación de ambas CNN.

La menor pérdida de validación de la CNN básica ocurrió en la época 6 (0.1345) y la de la CNN profunda en la época 3 (0.1565). Después, la pérdida de entrenamiento continuó bajando mientras la de validación aumentó: señal de sobreajuste, más visible en la CNN profunda. Los resultados por clase siguientes corresponden a los modelos al terminar la época 10; no se recuperaron automáticamente los parámetros de la época con menor pérdida.

8. Desempeño por clase

La accuracy puede dar una impresión incompleta porque hay 454 casos con mascarilla bien puesta y solo 16 con mascarilla mal puesta en validación. Se calcularon precisión, recall y F1 por clase; el F1 macro da igual peso a las tres clases [4].

Modelo/clase	Prec.	Recall	F1	n
Básica: bien	.9864	.9581	.9721	454
Básica: sin	.8409	.9867	.9080	75
Básica: mal	.4375	.4375	.4375	16
Prof.: bien	.9780	.9780	.9780	454
Prof.: sin	.8471	.9600	.9000	75
Prof.: mal	.6667	.2500	.3636	16

Tabla 7. Métricas por clase en validación; bien/sin/mal indican el uso de mascarilla.

La CNN profunda obtuvo mayor accuracy (0.9541 frente a 0.9468), pero la básica logró mejor F1 macro (0.7725 frente a 0.7472). En la clase de uso incorrecto, la básica detectó 7 de 16 casos y la profunda 4 de 16.

9. Matrices de confusión

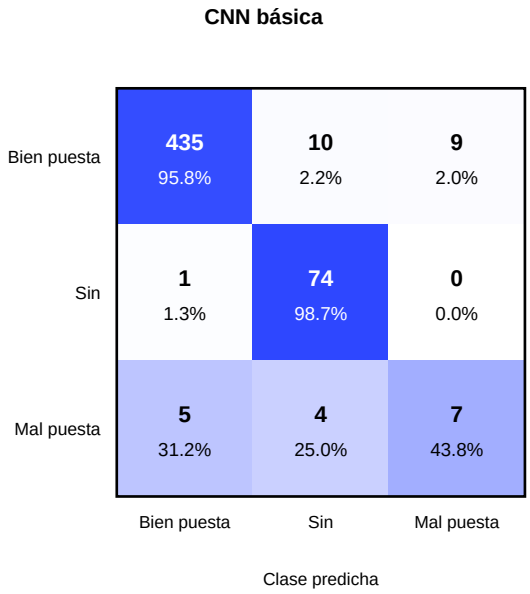


Figura 2a. Matriz de confusión de la CNN básica en validación.

En la Figura 2, la CNN básica clasificó correctamente 435 de 454 rostros con mascarilla bien puesta, 74 de 75 sin mascarilla y 7 de 16 con mascarilla mal puesta. De los nueve casos restantes de uso incorrecto, cinco fueron clasificados como bien puestos y cuatro como ausencia de mascarilla.

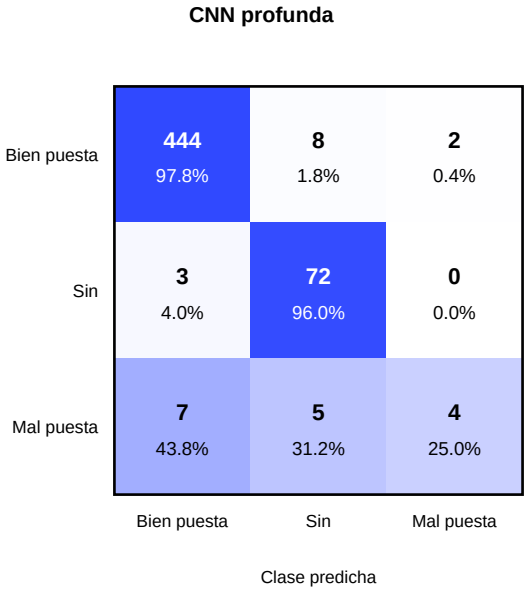


Figura 2b. Matriz de confusión de la CNN profunda en validación.

La CNN profunda reconoció 444 de 454, 72 de 75 y 4 de 16 casos, respectivamente. De los doce casos de uso incorrecto no detectados, siete se asignaron a mascarilla bien puesta y cinco a ausencia de mascarilla. La profunda generó menos falsas alarmas de uso incorrecto entre los rostros bien protegidos, pero omitió más casos reales de mal uso.

10. Selección provisional

Se seleccionó provisionalmente la CNN básica para la interfaz. Su F1 macro y su reconocimiento del uso incorrecto fueron superiores a los de la profunda, aunque esta alcanzó mejor accuracy general. El reducido número de ejemplos de uso incorrecto limita la firmeza de la comparación. La selección se refiere únicamente a las configuraciones evaluadas en este trabajo.

11. Demostración de la interfaz local

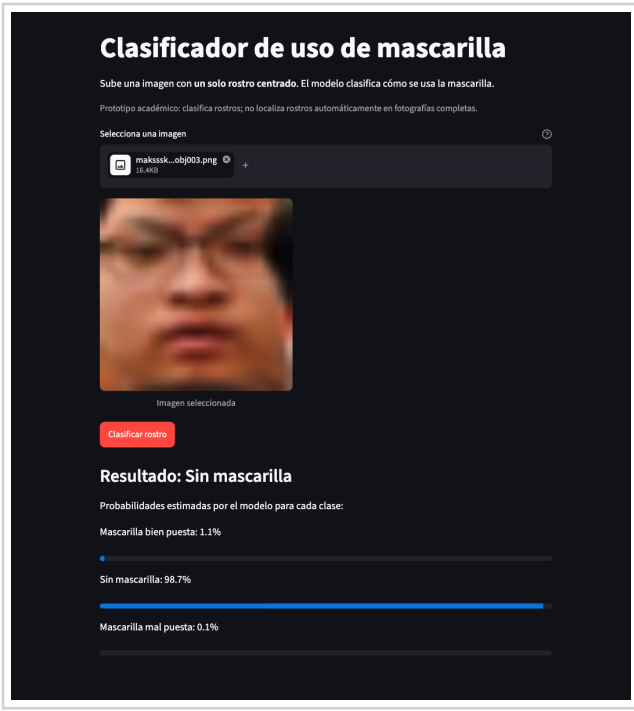


Figura 3a. Sin mascarilla; resultado mostrado: 98.7%.

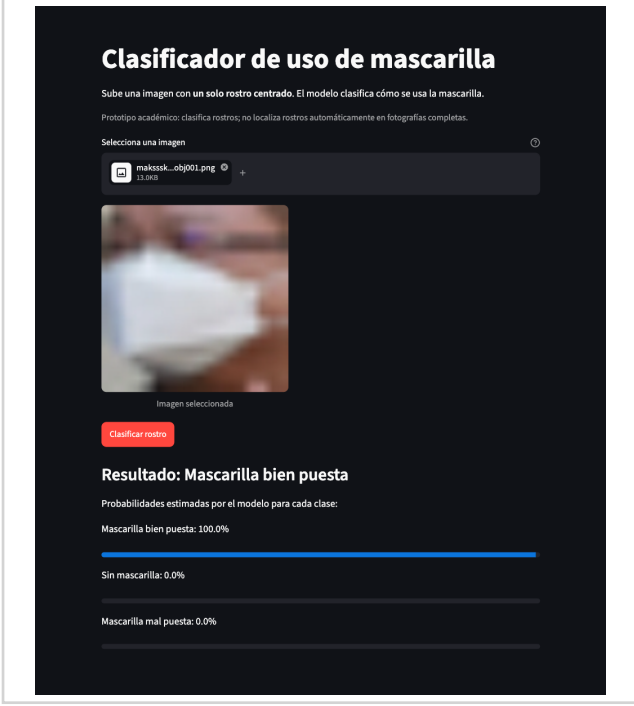


Figura 3b. Mascarilla bien puesta; resultado mostrado: 100.0%.

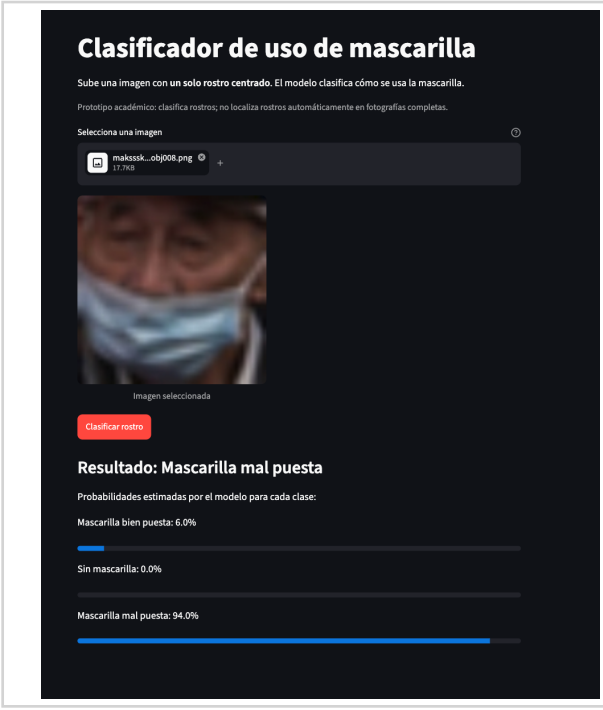


Figura 3c. Mascarilla mal puesta; resultado mostrado: 94.0%.

El modelo se guardó e integró en una interfaz local desarrollada con Streamlit. Se eligió esta herramienta porque permite recibir una imagen y presentar la predicción desde Python sin desarrollar una aplicación web completa [5]. El usuario sube un solo rostro centrado; la interfaz lo prepara como RGB de 128 x 128 píxeles y el modelo normaliza sus valores internamente. Se muestran la clase predicha y los valores asignados a las tres clases.

Las tres pruebas ilustradas en la Figura 3 coincidieron con la categoría esperada: sin mascarilla (98.7%), mascarilla bien puesta (100.0% mostrado con un decimal) y mascarilla mal puesta (94.0%). Son una demostración de funcionamiento fuera del notebook; el desempeño general se juzga mediante el conjunto de validación. La aplicación no localiza rostros dentro de fotografías completas.

12. Discusión

Las dos CNN aprendieron a clasificar los rostros recortados, pero la dificultad principal fue reconocer el uso incorrecto. Agregar un bloque convolucional aumentó ligeramente la accuracy general sin mejorar el F1 macro ni el recall de esa clase. La tendencia de las curvas muestra que entrenar más épocas no aseguró una mejora en validación.

La interfaz demuestra que el modelo guardado puede usarse fuera del notebook y permite explorar su aplicación como apoyo a la revisión del uso de mascarillas. Su alcance actual es el de un clasificador de rostros previamente recortados. En la clase de uso incorrecto hubo solo 83 ejemplos de entrenamiento y 16 de validación; unos pocos errores alteran mucho las métricas. El conjunto de prueba se mantuvo reservado para la evaluación final.

13. Conclusiones

Se prepararon 3,603 recortes de rostros a partir de 853 fotografías y se entrenaron dos CNN para distinguir las tres categorías. La división por fotografía evitó compartir rostros de una misma imagen entre los conjuntos.

La CNN profunda obtuvo mayor accuracy de validación (95.41%), mientras que la básica logró mejor F1 macro (0.7725) y reconoció más casos de mascarilla mal puesta (7 de 16). Por ello se seleccionó provisionalmente la básica para la interfaz. La aplicación permitió obtener predicciones fuera del notebook, pero

el prototipo todavía comete errores importantes en la clase de uso incorrecto y no localiza rostros automáticamente.

La comparación continuará con otras configuraciones antes de fijar el modelo del proyecto. El conjunto de prueba reservado servirá para evaluar la configuración elegida sin usar esos resultados para modificarla.

Referencias

[1] andrewmvd, "Face Mask Detection," Kaggle. https://www.kaggle.com/datasets/andrewmvd/face-mask-detection

[2] TensorFlow, "Image classification," TensorFlow Core. https://www.tensorflow.org/tutorials/images/classification

[3] D. P. Kingma y J. Ba, "Adam: A Method for Stochastic Optimization," International Conference on Learning Representations, 2015. https://arxiv.org/abs/1412.6980

[4] scikit-learn, "classification_report," documentación oficial. https://scikit-learn.org/stable/modules/generated/sklearn.metrics.classification_report.html

[5] Streamlit, "st.file_uploader," documentación oficial. https://docs.streamlit.io/develop/api-reference/widgets/st.file_uploader